Introdução à Programação

Aula 17: Arquivos Texto

Prof. Eduardo Corrêa Gonçalves

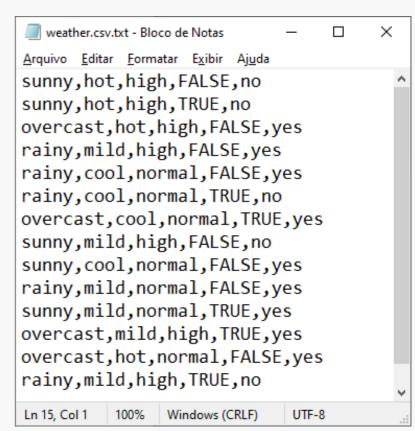
07/07/2020



Introdução (1/2)

O que é um Arquivo?

- Um arquivo é um conjunto de contíguo de bytes relacionados, mantido em algum dispositivo de armazenamento permanente (HD, pen drive, cartão de memória etc.).
 - Há vários tipos de arquivo.
- Porém, neste curso trabalharemos apenas com os arquivos texto.
- Trata-se do tipo de arquivo cujo conteúdo pode ser visualizado em qualquer editor de textos, como o bloco de notas.



Introdução (2/2)

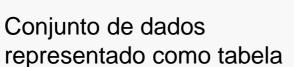
Arquivos Texto

- Como estatístico, uma das tarefas mais comuns que você realizará será ler, analisar e escrever (gravar) arquivos texto
- Nesta aula, trabalharemos principalmente com um tipo específico de arquivo texto conhecido como arquivo CSV.
 - CSV é um dos formatos mais utilizados para armazenar bases de dados (BDs) no formato tabular (dados dispostos em linhas e colunas).
 - Há vários sites na Internet que fornecem bases de dados nesse formato. Elas podem ser estudadas pelos estatísticos.

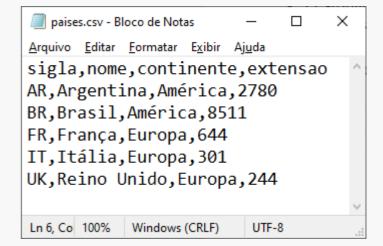
Arquivos CSV (1/3)

- Um CSV é um arquivo texto contendo um conjunto de dados a respeito de "alguma coisa" (algum objeto de estudo).
 - Exemplos: país, animal, pessoa, carro, etc.

1	sigla	nome	continente	extensao
2	AR	Argentina	América	2780
3	BR	Brasil	América	8511
4	FR	França	Europa	644
5	IT	Itália	Europa	301
6	UK	Reino Unido	Europa	244





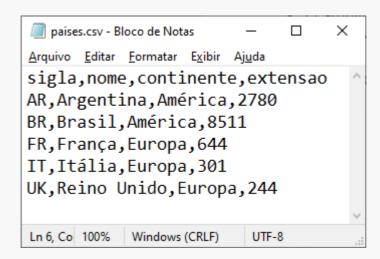


Mesmo conjunto de dados representado no formato CSV

Arquivos CSV (2/3)

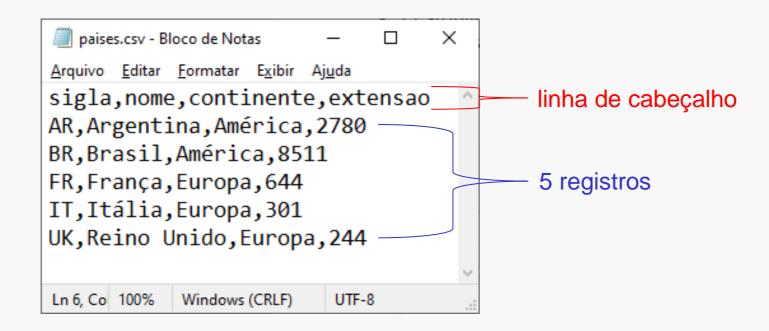
Formato CSV

- Cada linha corresponde a um registro (ou observação, no vocabulário dos estatísticos).
- As colunas são separadas por vírgula e representam os atributos (propriedades, ou variáveis no vocabulário dos estatísticos) dos registros.
- O arquivo pode ter uma 1^a linha de cabeçalho, com os nomes dos atributos. Isso torna o arquivo autodescritivo.



Arquivos CSV (3/3)

- **EXERCÍCIO**: digite e grave no HD ou pen-drive a base "países.csv"
 - Possui 5 registros. Cada um corresponde a um país.
 - Possui 4 atributos para descrever cada país: "sigla", "nome", "continente" e "extensão".
 - A 1^a linha é a linha de cabeçalho
 - Utilizaremos esse CSV para os exemplos da aula.



Outros exemplos de arquivos CSV (1/2)

- Exemplo 2: "animais.csv" (base de dados de animais)
 - 14 registros (cada um referente a um animal)
 - 3 atributos:
 - "animal" nome do animal
 - "fofura" escala de fofura (0 a 100)
 - "tamanho" escala de tamanho (0 a 100)

```
animal,fofura,tamanho
gatinho filhote,95,15
hamster,80,5
tarântula,8,3
cachorrinho filhote,90,20
crocodilo,5,40
golfinho,60,45
urso panda,75,45
lagosta, 2, 15
capivara,70,35
elefante,65,90
mosquito,1,1
peixinho dourado,25,2
cavalo,50,50
galinha,25,15
```

Outros exemplos de arquivos CSV (2/2)

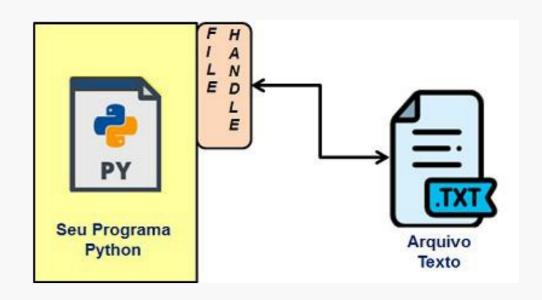
Exemplo 3: "notas.csv" (base de dados de notas de alunos)

- M0012023;9.8;9.5
- M0022023;5.3;4.1
- M0032023;2.5;8.0
- M0042023;7.5;7.5

- Veja que esse BD é um pouco diferente.
 - Não possui cabeçalho. Problema: ele deixa de ser autodescritivo.
 - Os dados são separados por ponto-evírgula em vez de vírgula.
- Mesmo assim, pode ser considerado um CSV!
- 4 registros (cada um referente a um aluno)
- 3 atributos:
 - Matrícula do aluno
 - Nota na 1^a prova
 - Nota na 2^a prova

Arquivos Texto no Python (1/11)

- Função open()
 - No Python padrão, é necessário usar a função open() para comandar a abertura de um arquivo.
 - Abrir significa pedir ao SO para encontrar o endereço de localização do arquivo no HD, pen drive, etc.
 - Ao encontrar o endereço do arquivo, o SO retornará um file handle para o programa.
 - O file handle não é a mesma coisa que conteúdo (dados) do arquivo.
 - Na verdade, é uma ferramenta que permite ao programador "manejar" os dados do arquivo.



Função open() (1/2)

- Função open() Importância
 - Trabalhar com arquivos via open() / file handle não é tão "confortável" como trabalhar com um Data Frame da linguagem R ou do pacote pandas do Python (como você verá no futuro...).
 - No entanto, é importante saber lidar com a função open() pelos seguintes motivos:
 - É uma ferramenta eficiente para realizar o acesso sequencial (linha por linha). Muitas vezes, esta é a única opção viável para lidar com bases muito grandes.
 - É a ferramenta mais simples para lidar com **arquivos separados por colunas** (formato raro hoje em dia, mas ainda usado).
 - Trata-se de uma função do Python padrão. Ou seja: permite com que você trabalhe com arquivos sem precisar instalar ou importar nenhum pacote adicional.

Função open() (2/2)

Função open() – Sintaxe

```
f = open(nome_arq, modo)
```

- nome_arq: nome do arquivo (incluindo especificação do diretório).
 Único parâmetro obrigatório.
- modo:
 - 'r': abre o arquivo para leitura (default)
 - 'w': abre o arquivo para escrita, eliminando a versão anterior.
 - 'a': abre o arquivo no modo append. Se o arquivo existir, as novas linhas serão inseridas no final.
 - 'rb', 'wb', 'ab' nos permitem trabalhar com arquivos binários, em vez de arquivos texto.
- Por exemplo, comando abaixo, abre para leitura o arquivo 'weather.csv", localizado na pasta "c:\bases"
 - f = open('C:/bases/weather.csv')

Acesso Sequencial (1/6)

- O que é Acesso Sequencial?
 - A forma mais comum de acessar arquivos texto no Python padrão é processando linha por linha, sequencialmente.
 - Neste modelo, o Python permite com que um arquivo seja visto como uma coleção de linhas.
 - É como se fosse uma fila de linhas. Podemos "desenfileirálas" uma por uma na ordem em que estão dispostas no arquivo.
 - Muito eficiente em termos de ocupação de memória. A cada iteração, apenas uma linha reside na memória.

arq_teste.csv

```
Rakesh, 25
Vijay, 43
Yash, 18
Juily, 51
Vidur, 39
```



```
f = open('arq_teste.csv')
for linha in f:
    print(linha)
```

f.close()

>>> Rakesh,25

Vijay,43

Yash,18

Juily,51

Vidur,39

Acesso Sequencial (2/6)

- Acesso Sequencial Sintaxe:
 - A sintaxe básica para ler um arquivo sequencialmente é muito simples:

for linha in f: comandos

- A cada iteração do for, a próxima linha será armazenada como uma string na variável "linha".
- Veja que incialmente, precisamos abrir o arquivo com o método open().
- No final, fechá-lo com o método close().
 - Na operação de leitura isso não é obrigatório, mas é uma boa prática.

arq_teste.csv

```
Rakesh, 25
Vijay, 43
Yash, 18
Juily, 51
Vidur, 39
```



```
f = open('arq_teste.csv')
for linha in f:
    print(linha)
```

f.close()

>>>

Rakesh,25

Vijay,43

Yash,18

Juily,51

Vidur,39

Acesso Sequencial (3/6)

- Problema: o caractere "\n"
 - Ao executar o exemplo, você deve ter percebido que uma linha em branco foi impressa depois de cada print().
 - Isto ocorreu porque o último caractere de uma linha do arquivo é na verdade "invisível".
 - Ele se chama fim de linha ou newline e é representado por "\n" nas linguagens de programação.
 - Na verdade o fim de linha no Windows é representado por dois caracteres invisíveis (CR + LF). No Windows e Mac, apenas um (LF).
 - Para simplificar, referenciaremos o fim de linha sempre como \n

```
f = open('arq_teste.csv')
for linha in f:
  print(linha)
f.close()
>>>
Rakesh,25
Vijay,43
Yash,18
Juily,51
Vidur,39
```

Acesso Sequencial (4/6)

- Problema: o caractere "\n"
 - A primeira linha do arquivo é Rakesh,25
 - Veja que quando mandamos imprimir o comprimento dessa linha, o valor retornado é 10, embora a gente só enxergue 9 caracteres.
 - A mesma coisa ocorre para as demais linhas !!!

```
f = open('arq_teste.csv')
for linha in f:
  print("comprimento = ", len(linha))
  print(linha)
f.close()
>>>
comprimento = 10
Rakesh,25
comprimento = 9
Vijay,43
comprimento = 8
Yash,18
comprimento = 9
Juily,51
comprimento = 9
Vidur, 39
```

Acesso Sequencial (5/6)

- Solução: usar o método rstrip()
 - Para descartar o "\n" após ler uma linha, você pode utilizar:
 - linha.rstrip():
 - Este método remove caracteres do tipo whitespace que estiverem à direita de uma string.
 - Caracteres como espaço em branco, "\t" e "\n" são considerados whitespace.

```
f = open('arq_teste.csv')
for linha in f:
    print(linha.rstrip())

f.close()

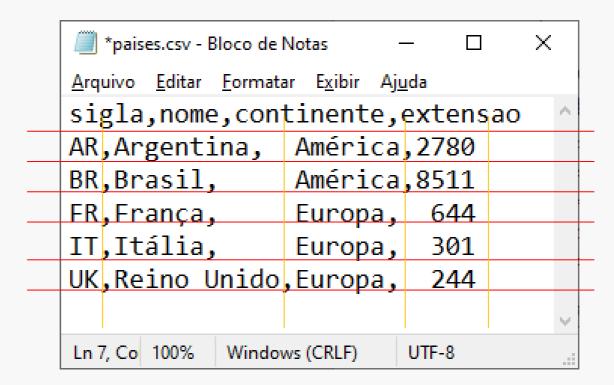
>>>
Rakesh,25
Vijay,43
Yash,18
Juily,51
Vidur,39
```

Acesso Sequencial (6/6)

- Acesso Sequencial Resumo
 - É o modo de acesso a arquivos mais usado no Python padrão.
 - Recupera as linhas do arquivo, uma por uma, da primeira à ultima, em um laço for.
 - Cada linha é sempre lida para uma variável string.
 - Só permite avançar as linhas, nunca recuar.
 - Eficiente, especialmente na questão da ocupação de memória.
 - Nos próximos slides, mostraremos a receita para processar sequencialmente bases de dados texto em dois diferentes formatos:
 - Arquivo CSV;
 - Arquivo separado por colunas;
 - Para rodar os exemplos, digite as bases de dados, salve com o nome indicado e as coloque na mesma pasta dos programas.

Processando Arquivos CSV (1/8)

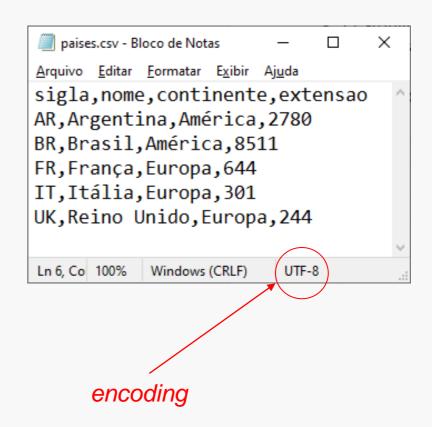
- Como processar um arquivo CSV?
 - Primeiro precisamos abrir o arquivo com open() especificando o nome e encoding do arquivo corretamente.
 - Depois fazer o acesso sequencial, linha por linha, usando for.
 - Para cada linha, é preciso separar as informações em cada coluna.



Processando Arquivos CSV (2/8)

- Passo 1: abrir o arquivo com open()
 - Basta especificar:
 - (1) o nome caminho e nome do arquivo.
 - (2) O encoding do arquivo
 - Mas o que é encoding????

```
f = open('paises.csv', encoding="utf-8")
```



Processando Arquivos CSV (3/8)

Encoding

- Encoding é o método que foi usado para converter códigos Unicode para bytes ao salvar o arquivo texto.
- Existem muitos encodings, mas os mais usados são "ansi" e "utf-8".
- Por padrão, a função open() considera que o encoding do arquivo é "ansi". Se for utf-8, você tem que indicar, como foi feito no programa ao lado.

```
f = open('paises.csv', encoding="utf-8")
for linha in f:
    print(linha.rstrip())

f.close()

>>>
    sigla,nome,continente,extensao
    AR,Argentina,América,2780
BR,Brasil,América,8511
FR,França,Europa,644
IT,Itália,Europa,301
UK,Reino Unido,Europa,244
```

Processando Arquivos CSV (4/8)

Encoding

- E o que acontece se o encoding errado for usado?
- Nesse caso, alguns caracteres (ex.: caracteres acentuados) vão ser lidos de forma incorreta.
- Ao tentar exibi-los, vai aparecer "lixo" na tela.
- Veja ao lado, onde um arquivo utf-8 é lido como ansi (ansi é o padrão default, mas é o encoding errado para esse arquivo).

```
f = open('paises.csv')
for linha in f:
    print(linha.rstrip())

f.close()

>>>
    sigla,nome,continente,extensao
    AR,Argentina,América,2780
BR,Brasil,América,8511
FR,França,Europa,644
IT,ItÃ;lia,Europa,301
```

UK, Reino Unido, Europa, 244

Processando Arquivos CSV (5/8)

- Encoding Receita de Bolo
 - Ao tentar abrir um arquivo, se você não souber o encoding, você pode primeiro usar o open() especificando encoding = 'utf-8'
 - Isso porque o UTF-8 é o encoding mais comum.
 - Se der problema (aparecer os caracteres lixo) simplesmente remova o parâmetro.

```
f = open('paises.csv', encoding="utf-8")
for linha in f:
    print(linha.rstrip())

f.close()

>>>
    sigla,nome,continente,extensao
    AR,Argentina,América,2780
BR,Brasil,América,8511
FR,França,Europa,644
IT,Itália,Europa,301
UK,Reino Unido,Europa,244
```

Processando Arquivos CSV (6/8)

- Passo 2: fazer o acesso sequencial separando linhas e colunas
 - Ao lado, a receita completa:
 - O for linha in f: percorre as linhas
 - Para cada linha, usamos linha = linha.rstrip() para remover o '\n' à direita.
 - Depois usamos lst = linha.split(",") para transformar cada linha em uma lista de strings (basta mandar separar pela "," no caso desse arquivo).
 - Assim cada atributo é separado em uma posição da lista.

```
f = open('paises.csv', encoding="utf-8")
for linha in f:
     linha = linha.rstrip()
     colunas = linha.split(",")
     print(colunas)
f.close()
>>>
'sigla', 'nome', 'continente', 'extensao']
['AR', 'Argentina', 'América', '2780']
['BR', 'Brasil', 'América', '8511']
['FR', 'França', 'Europa', '644']
['IT', 'Itália', 'Europa', '301']
['UK', 'Reino Unido', 'Europa', '244']
```

Processando Arquivos CSV (7/8)

- Passo 2: fazer o acesso sequencial separando linhas e colunas
 - Observe que, para qualquer linha, na lista colunas teremos:
 - A sigla na posição 0
 - O nome na pos. 1
 - O continente na pos. 2
 - A extensão na pos. 3
 - Sendo assim, basta observar o padrão acima para fazer qualquer programa que faça um estudo no arquivo.

```
f = open('paises.csv', encoding="utf-8")
for linha in f:
     linha = linha.rstrip()
     colunas = linha.split(",")
     print(colunas)
f.close()
>>>
'sigla', 'nome', 'continente', 'extensao']
['AR', 'Argentina', 'América', '2780']
['BR', 'Brasil', 'América', '8511']
['FR', 'França', 'Europa', '644']
['IT', 'Itália', 'Europa', '301']
['UK', 'Reino Unido', 'Europa', '244']
```

Processando Arquivos CSV (8/8)

- Agora é só usar a receita!
 - Acabamos de ver a receita básica para processar um arquivo CSV:
 - PASSO 1 SEPARAR AS LINHAS:
 - usar open() com for nas linhas para fazer o acesso sequencial.
 - PASSO 2 SEPARAR AS COLUNAS:
 - Dentro do laço for, usar split() paraseparar as colunas de cada linha, indicando o separador adequado. -
 - Nesse caso é vírgula, mas pode ser outro.
- × *paises.csv - Bloco de Notas Arquivo Editar Formatar Exibir Ajuda sigla, nome, continente, extensao AR,Argentina, América, 2780 BR,Brasil, América, 8511 FR,França, 644 Europa, IT,Itália, 301 Europa, UK,Reino Unido,Europa, 244 Ln 7, Co 100% Windows (CRLF) UTF-8
- Nos exercícios seguintes, vermos como aplicar essa receita na prática.
 - Aproveitaremos para mostrar mais algumas coisas importantes, como a forma de desconsiderar o cabeçalho e a necessidade de conversão de atributos numéricos.

Exercícios Resolvidos (1/5)

 Exercício Resolvido 1: contar o total de países da Europa e da América

```
1 # contar total de países da Europa e da América
  2 f = open('paises.csv', encoding="utf-8")
  3 f.readline() # usado para pular a linha de cabeçalho
  4 tot eu = tot am = 0
  6 for linha in f: # para cada linha...
         linha = linha.rstrip() # tira o \n do final
         colunas = linha.split(",") # separa as colunas em uma lista
         if colunas[2] == 'Europa': tot eu += 1
         elif colunas[2] == 'América': tot am += 1
 10
 11
 12 f.close()
    print(f'Total de países da Europa: {tot eu}')
    print(f'Total de países da América: {tot am}')
 14
 15
Shell
>>> %Run conta total eu am.py
Total de países da Europa: 3
 Total de países da América: 2
                                                                Python 3.10.4
```

Exercícios Resolvidos (2/5)

 Exercício Resolvido 1: contar o total de países da Europa e da América

```
# contar total de países da Europa e da América
f = open('paises.csv', encoding="utf-8")
f.readline() # usado para pular a linha de cabeçalho
tot_eu = tot_am = 0

for linha in f: # para cada linha...
linha = linha.rstrip() # tira o \n do final
colunas = linha.split(",") # separa as colunas em uma lista
if colunas[2] == 'Europa': tot_eu += 1
elif colunas[2] == 'América': tot_am += 1

f.close()
print(f'Total de países da Europa: {tot_eu}')
print(f'Total de países da América: {tot_am}')
```

IMPORTANTE !!!

- Antes do for, usamos f.readline() para forçar a leitura da linha de cabeçalho.
- readline() é um método que lê uma linha e avança para a próxima
- Isso é uma forma de "descartar" a linha, já que ela não possui dados.

Exercícios Resolvidos (3/5)

 Exercício Resolvido 1: contar o total de países da Europa e da América

```
1 # contar total de países da Europa e da América
2 f = open('paises.csv', encoding="utf-8")
3 f.readline() # usado para pular a linha de cabeçalho
4 tot eu = tot am = 0
   for linha in f: # para cada linha...
6
       linha = linha.rstrip() # tira o \n do final
       colunas = linha.split(",") # separa as colunas em uma lista
8
       if colunas[2] == 'Europa': tot eu += 1
       elif colunas[2] == 'América': tot am += 1
10
11
12 f.close()
print(f'Total de países da Europa: {tot_eu}')
14 print(f'Total de países da América: {tot_am}')
```

- IMPORTANTE (2) !!!
 - Os resultados são computados dentro do for (onde processamos cada linha)

Exercícios Resolvidos (4/5)

• Exercício Resolvido 2: qual a extensão média dos países da Europa?

```
1 # extensao media dos países da Europa
  2 f = open('paises.csv', encoding="utf-8")
  3 f.readline() # usado para pular a linha de cabeçalho
    soma ext eu = tot eu = 0
  6 for linha in f: # para cada linha...
         linha = linha.rstrip() # tira o \n do final
  8
         colunas = linha.split(",") # separa as colunas em uma lista
         if colunas[2] == 'Europa':
             tot eu += 1
 10
 11
             soma_ext_eu += float(colunas[3])
 12
 13 f.close()
     print(f'Extensão média dos países da Europa: {soma_ext_eu / tot_eu: .2f}')
 14
15
Shell
>>> %Run extensao media eu.py
 Extensão média dos países da Europa: 396.33
```

Exercícios Resolvidos (5/5)

• Exercício Resolvido 2: qual a extensão média dos países da Europa?

```
1 # extensao media dos países da Europa
  2 f = open('paises.csv', encoding="utf-8")
  3 f.readline() # usado para pular a linha de cabeçalho
    soma ext eu = tot eu = 0
  6 for linha in f: # para cada linha...
         linha = linha.rstrip() # tira o \n do final
         colunas = linha.split(",") ≯ separa as colunas em uma lista
         if colunas[2] == 'Europa':
             tot eu += 1
 10
             soma_ext_eu += float(colunas[3])
 11
 12
 13 f.close()
     print(f'Extensão média dos países da Europa: {soma_ext_eu / tot_eu: .2f}')
15
Shell
>>> %Run extensao media eu.py
 Extensão média dos países da Europa:
                                     396.33
```

IMPORTANTE !!!

- "colunas" é uma lista de strings (o split() sempre gera lista de strings)
- Por isso, sempre que você precisar fazer uma conta com algo que estiver nessa lista, será preciso converter o valor para int ou float !!!

Arquivos Separados por Colunas

- Ao contrário do CSV, não possui caractere separador. Veja o exemplo abaixo:
 - Em "arq_colunas.txt" temos duas variáveis:
 - Uma delas numérica, da coluna 0 a 3.
 - A outra é categórica, da coluna 4 a 8.
 - Solução: Usar o fatiamento para separar as variáveis.

arq_colunas.txt

1001aaaaa 1002bbbbb 1003cccc 1004ddddd 1005eeeee



```
nomeArq = 'ARQ_COLUNAS.txt'
f = open(nomeArq)
for linha in f:
  linha = linha.rstrip()
  v1 = int(linha[:4]) #usei int p/ converter v1 p/ inteiro
  v2 = linha[4:]
  print(v1, v2)
>>>
1001 aaaaa
1002 bbbbb
1003 ccccc
1004 ddddd
1005 eeeee
```

Método read()

- Lendo um arquivo inteiro para uma string read()
 - Com o método read(), todos os caracteres do arquivo do primeiro ao último, incluindo os "\n" – são armazenados em um único "stringão"

produtos.txt

1001Leite 1002Biscoito 1003Café 1004Torradas 1005Chá



```
nomeArq = 'PRODUTOS.txt'
f = open(nomeArq)
conteudo = f.read()
print(conteudo)
>>>
1001Leite
```

1002Biscoito

1003Café

1004Torradas

1005Chá

Método readlines()

- Lendo um arquivo inteiro para uma lista de strings readlines()
 - Com o método readlines(), produz-se uma lista de strings.
 - Cada elemento da lista consistirá em uma linha do arquivo
 - * * CUIDADO: os caracteres "\n" de cada linha também são levados.

produtos.txt

1001Leite 1002Biscoito 1003Café 1004Torradas 1005Chá



```
nomeArq = 'PRODUTOS.txt'

f = open(nomeArq)

conteudo = f.readlines()

print(conteudo)

>>>

['1001Leite\n', '1002Biscoito\n', '1003Café\n',
 '1004Torradas\n', '1005Chá\n']
```

Gravando Arquivos (1/5)

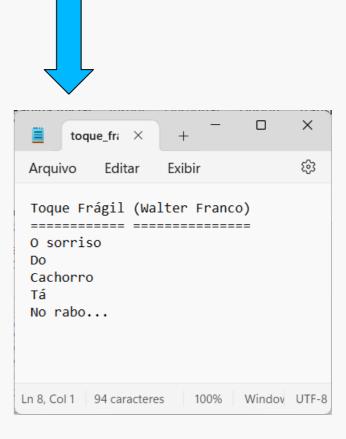
- I. Gravando um Arquivo (1/2)
 - Você deve abrir o arquivo utilizando o modo "w".
 - CUIDADO 1: caso um arquivo com mesmo nome exista, ele será destruído!
 - <u>CUIDADO 2</u>: se quiser gravar com o encoding UTF-8, é preciso usar o open() especificando encoding = 'utf-8'
 - Quando a gravação terminar, é necessário utilizar a função close() para fechar o arquivo.
 - A função write() é utilizada para gravar uma linha.
 - IMPORTANTE: ela só consegue gravar strings. Se tiver algum dado numérico você terá que converter para string.
 - **Obs.**: sempre que você quiser uma quebra de linha, deverá especificar explicitamente o "/n"

Gravando Arquivos (2/5)

I. Gravando um Arquivo (2/2)

```
fout = open('toque_fragil.txt', 'w', encoding = "utf-8")
msg1 = "O sorriso\n"
msg2 = "Do\n"
msg3 = "Cachorro\n"
msg4 = "Tá\n"
msg5 = "No rabo...\n"

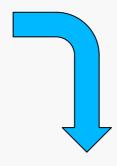
fout.write("Toque Frágil (Walter Franco)\n")
fout.write("===========")
fout.write("\n")
fout.write(msg1 + msg2 + msg3 + msg4 + msg5)
fout.close()
```



Gravando Arquivos (3/5)

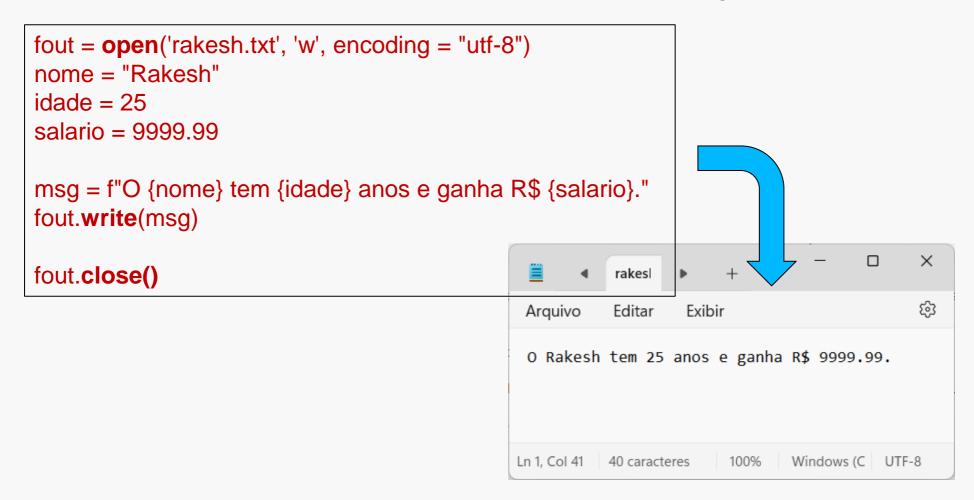
- II. Inserindo Linhas no Final de um Arquivo Existente
 - Você deve abrir o arquivo utilizando o modo "a" (append).

```
fout = open('C:/CursoPython/toque_fragil.txt', 'a')
fout.write("######################")
fout.write("*************************
fout.close()
```



Gravando Arquivos (4/5)

- Como gravar dados numéricos?
 - Como write() aceita apenas strings, você precisa:
 - converter qualquer dado numérico para string se quiser gravá-lo.
 - Por exemplo, você pode colocar numa f-string



Gravando Arquivos (5/5)

- Como gravar dados numéricos?
 - Outra forma, dessa vez com concatenação e str()

```
fout = open('rakesh.txt', 'w', encoding = "utf-8")
nome = "Rakesh"
idade = 25
salario = 9999.99
fout.write("O " + nome + " tem " + str(idade) + " anos e ganha R$ " + str(salario))
fout.close()
                                                                                            X
                                                         rakes
                                                                                            £
                                               Arquivo
                                                         Editar
                                                                 Exibir
                                               O Rakesh tem 25 anos e ganha R$ 9999.99
                                              Ln 1, Col 40
                                                                      100%
                                                                             Windows (C UTF-8
                                                        39 caracteres
```